Epidemische Informationsausbreitung I Algorithmen für verteilte Systeme

Sebastian Forster

Universität Salzburg



Dieses Werk ist unter einer Creative Commons Namensnennung 4.0 International Lizenz lizenziert.

Point-to-Point Netzwerke:

 Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen

Point-to-Point Netzwerke:

- Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen
- Bandbreitenbeschränkung: Mit jeder hergestellte Verbindung kann nur eine Nachricht beschränkter Größe gesendet bzw. empfangen werden.

Point-to-Point Netzwerke:

- Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen
- Bandbreitenbeschränkung: Mit jeder hergestellte Verbindung kann nur eine Nachricht beschränkter Größe gesendet bzw. empfangen werden.
- Modelliert insbesondere Ende-zu-Ende-Verbindungen über niedere Netzwerkschichten

Point-to-Point Netzwerke:

- Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen
- Bandbreitenbeschränkung: Mit jeder hergestellte Verbindung kann nur eine Nachricht beschränkter Größe gesendet bzw. empfangen werden.
- Modelliert insbesondere Ende-zu-Ende-Verbindungen über niedere Netzwerkschichten

Zentrale Fragestellung: Effiziente Verbreitung einer Information an alle Knoten des Netzwerks

Point-to-Point Netzwerke:

- Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen
- Bandbreitenbeschränkung: Mit jeder hergestellte Verbindung kann nur eine Nachricht beschränkter Größe gesendet bzw. empfangen werden.
- Modelliert insbesondere Ende-zu-Ende-Verbindungen über niedere Netzwerkschichten

Zentrale Fragestellung: Effiziente Verbreitung einer Information an alle Knoten des Netzwerks

Broadcast durch "Flooding" nicht möglich!

Point-to-Point Netzwerke:

- Jeder Knoten kann pro Runde nur mit jeweils einem anderen Knoten eine Verbindung herstellen
- Bandbreitenbeschränkung: Mit jeder hergestellte Verbindung kann nur eine Nachricht beschränkter Größe gesendet bzw. empfangen werden.
- Modelliert insbesondere Ende-zu-Ende-Verbindungen über niedere Netzwerkschichten

Zentrale Fragestellung: Effiziente Verbreitung einer Information an alle Knoten des Netzwerks

Broadcast durch "Flooding" nicht möglich!

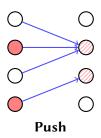
Motivation:

- Replizierte Datenbanken in Peer-to-Peer-Netzwerken
- Gleicher Datenbestand an allen Knoten, der konsistent gehalten wird
- Neue Information eines Knotens wird an alle anderen Knoten verteilt

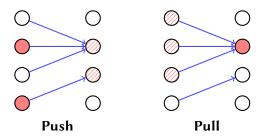
• Netzwerkstruktur: vollständiger Graph mit n Knoten

- Netzwerkstruktur: vollständiger Graph mit *n* Knoten
- Kommunikation findet in synchronen Runden statt
- In jeder Runde kann jeder Knoten einen anderen Knoten anrufen

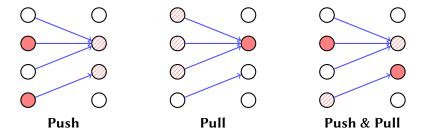
- Netzwerkstruktur: vollständiger Graph mit n Knoten
- Kommunikation findet in synchronen Runden statt
- In jeder Runde kann jeder Knoten einen anderen Knoten anrufen
- Drei Kommunikationsmodelle:
 - Push: Der Anrufer informiert den Angerufenen

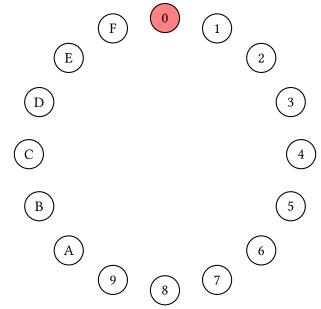


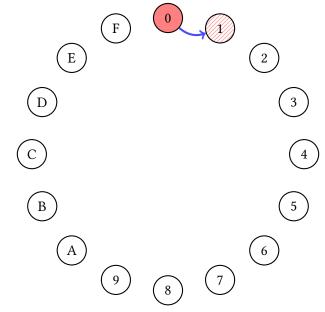
- Netzwerkstruktur: vollständiger Graph mit n Knoten
- Kommunikation findet in synchronen Runden statt
- In jeder Runde kann jeder Knoten einen anderen Knoten anrufen
- Drei Kommunikationsmodelle:
 - Push: Der Anrufer informiert den Angerufenen
 - Pull: Der Angerufene informiert den Anrufer

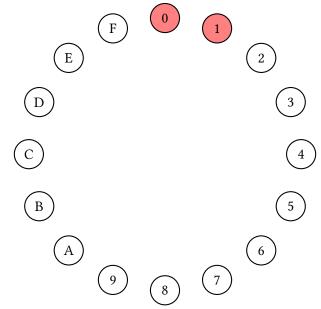


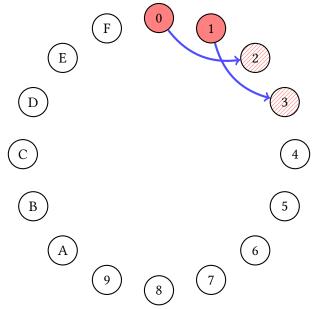
- Netzwerkstruktur: vollständiger Graph mit n Knoten
- Kommunikation findet in synchronen Runden statt
- In jeder Runde kann jeder Knoten einen anderen Knoten anrufen
- Drei Kommunikationsmodelle:
 - **1** Push: Der Anrufer informiert den Angerufenen
 - Pull: Der Angerufene informiert den Anrufer
 - Push & Pull: Kombination von Push und Pull

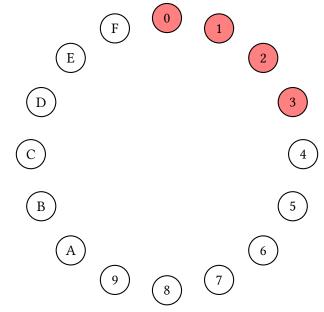


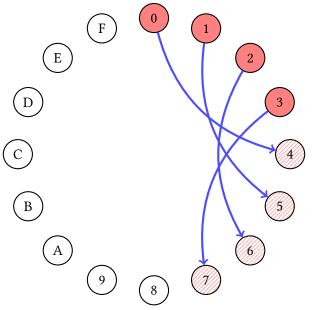


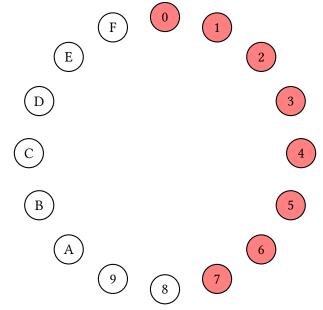


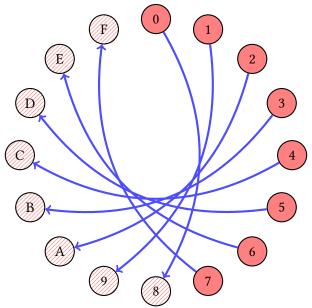


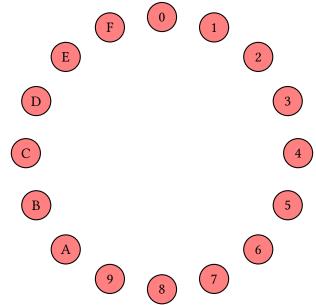


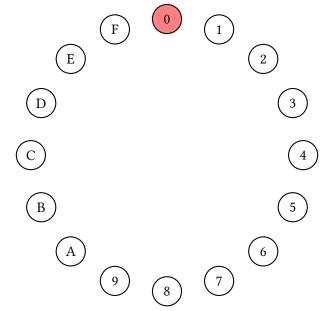


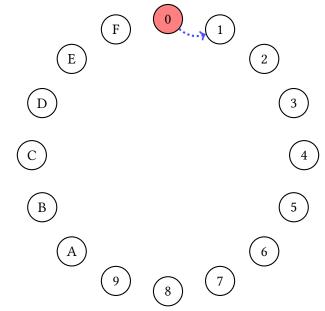


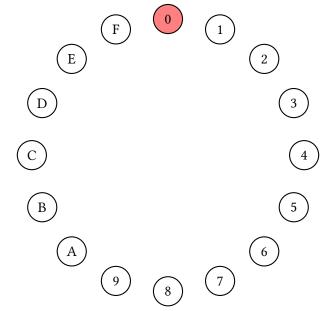


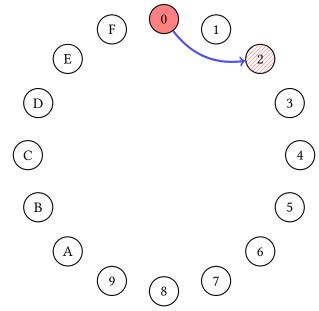


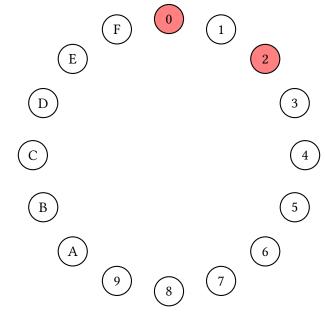


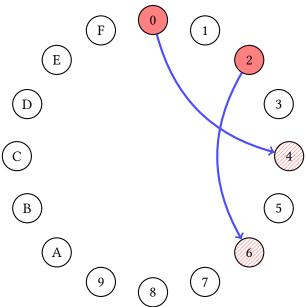


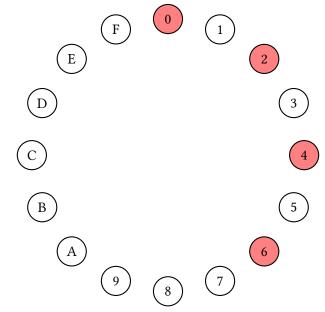


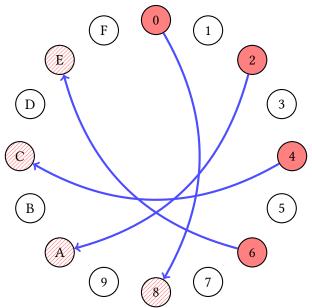


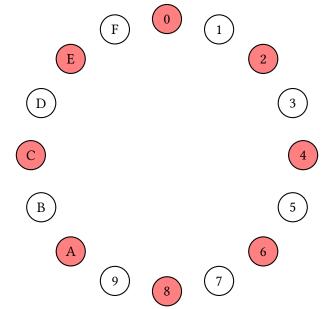












Deterministischer Algorithmus:

• Insgesamt O(n) Nachrichten in $O(\log n)$ Runden

Deterministischer Algorithmus:

Insgesamt O(n) Nachrichten in O(log n) Runden
 Optimal, da jeder Knoten mit einer Nachricht informiert werden muss und sich
 Anzahl informierter Knoten in jeder Runde bestenfalls verdoppeln kann

Deterministischer Algorithmus:

- Insgesamt O(n) Nachrichten in O(log n) Runden
 Optimal, da jeder Knoten mit einer Nachricht informiert werden muss und sich
 Anzahl informierter Knoten in jeder Runde bestenfalls verdoppeln kann
- Nachteile:
 - Keine Fehlertoleranz bei unzuverlässigen Knoten oder Verbindungen

Deterministischer Algorithmus:

- Insgesamt O(n) Nachrichten in O(log n) Runden
 Optimal, da jeder Knoten mit einer Nachricht informiert werden muss und sich
 Anzahl informierter Knoten in jeder Runde bestenfalls verdoppeln kann
- Nachteile:
 - Keine Fehlertoleranz bei unzuverlässigen Knoten oder Verbindungen
 - Jedem Knoten müssen alle anderen Knoten bekannt sein

Deterministischer Algorithmus:

- Insgesamt O(n) Nachrichten in O(log n) Runden
 Optimal, da jeder Knoten mit einer Nachricht informiert werden muss und sich
 Anzahl informierter Knoten in jeder Runde bestenfalls verdoppeln kann
- Nachteile:
 - Keine Fehlertoleranz bei unzuverlässigen Knoten oder Verbindungen
 - 2 Jedem Knoten müssen alle anderen Knoten bekannt sein
 - 3 Übertragung auf Pull-Modell unklar

Epicast als Ersatz für Broadcast [Demers et al. 87]

Epicast:

• Ausbreitung der Information wie ein Virus oder ein Gerücht

Epicast:

 Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion

Epicast:

- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist

Epicast:

- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

Epicast:

- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

Random-Phone-Call-Modell:

 In jeder Runde ruft jeder Knoten einen uniform zufällig gewählten Knoten and

Epicast:

- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

- In jeder Runde ruft jeder Knoten einen uniform zufällig gewählten Knoten and
- Der Einfachheit halber: Knoten kann auch sich selbst anrufen

Epicast:

- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

- In jeder Runde ruft jeder Knoten einen uniform zufällig gewählten Knoten and
- Der Einfachheit halber: Knoten kann auch sich selbst anrufen
- Somit: Knoten u ruft Konten v mit Wahrscheinlichkeit $\frac{1}{n}$ an

Epicast:

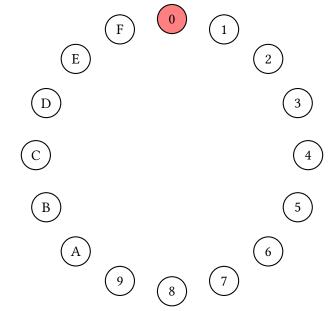
- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

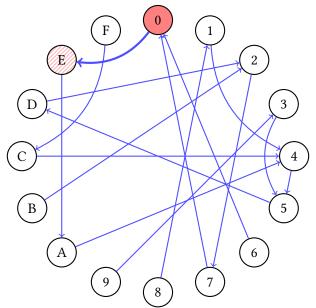
- In jeder Runde ruft jeder Knoten einen uniform zufällig gewählten Knoten and
- Der Einfachheit halber: Knoten kann auch sich selbst anrufen
- Somit: Knoten u ruft Konten v mit Wahrscheinlichkeit $\frac{1}{n}$ an
- Zufallsauswahl ohne explizite Kenntnis der anderen Knoten

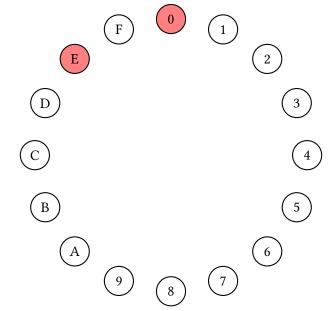
Epicast:

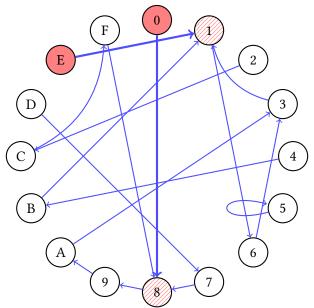
- Ausbreitung der Information wie ein Virus oder ein Gerücht Wir bezeichnen Weitergabe der Information als Infektion
- Jeder Knoten gibt die Information durch Zufallsauswahl weiter, bis sie allen Knoten bekannt ist
- Vorteile: schnell, robust, einfach
- Nachteil: Nachrichtenoverhead

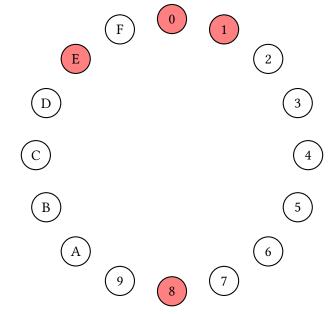
- In jeder Runde ruft jeder Knoten einen uniform zufällig gewählten Knoten and
- Der Einfachheit halber: Knoten kann auch sich selbst anrufen
- Somit: Knoten u ruft Konten v mit Wahrscheinlichkeit $\frac{1}{n}$ an
- Zufallsauswahl ohne explizite Kenntnis der anderen Knoten
 Zufällige Adressierung wird in vielen Peer-to-Peer-Netzwerken unterstützt

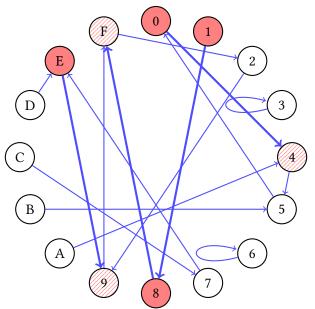


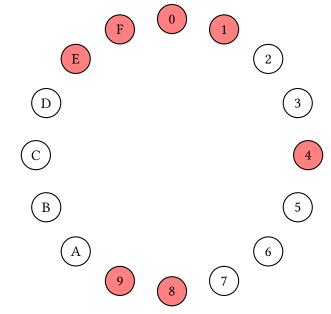


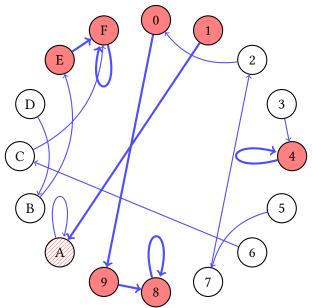


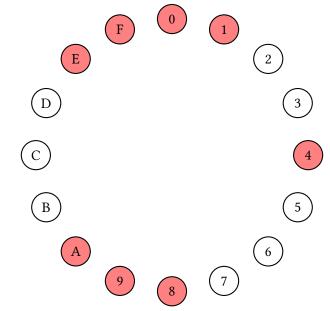


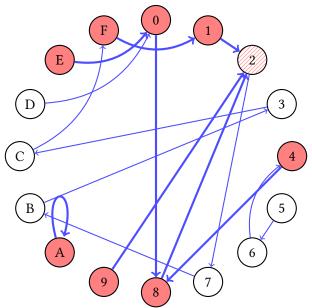


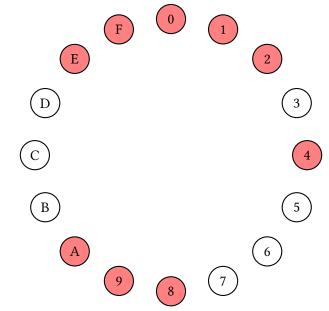


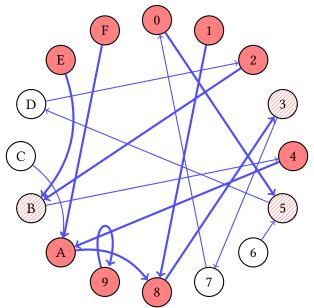


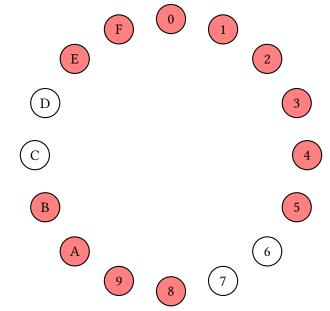


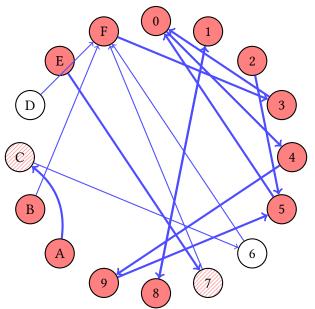


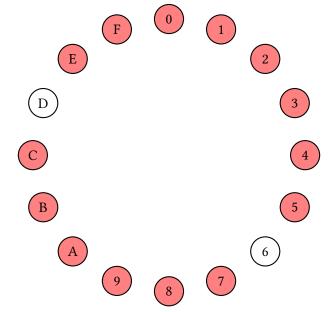


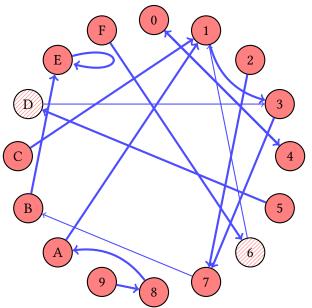


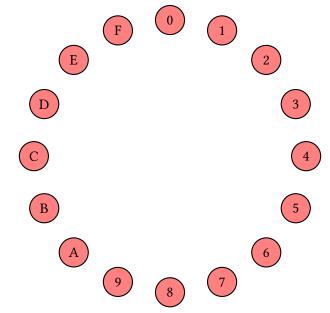












Frage: Wie lange es dauert bis alle Knoten infiziert sind, wenn anfangs ein Knoten infiziert ist?

Frage: Wie lange es dauert bis alle Knoten infiziert sind, wenn anfangs ein Knoten infiziert ist?

Theorem ([Frieze/Grimmett '85])

Im Push-Modell sind nach $t = O(\log n)$ Runden mit hoher Wahrscheinlichkeit alle Knoten infiziert.

Frage: Wie lange es dauert bis alle Knoten infiziert sind, wenn anfangs ein Knoten infiziert ist?

Theorem ([Frieze/Grimmett '85])

Im Push-Modell sind nach $t = O(\log n)$ Runden mit hoher Wahrscheinlichkeit alle Knoten infiziert.

Anmerkungen:

 Mit zusätzlichem Zeitstempel kann überprüft werden, ob mit hoher Wahrscheinlichkeit bereits alle Knoten infiziert sind und Ausbreitung der Information gestoppt werden kann

Frage: Wie lange es dauert bis alle Knoten infiziert sind, wenn anfangs ein Knoten infiziert ist?

Theorem ([Frieze/Grimmett '85])

Im Push-Modell sind nach $t = O(\log n)$ Runden mit hoher Wahrscheinlichkeit alle Knoten infiziert.

Anmerkungen:

- Mit zusätzlichem Zeitstempel kann überprüft werden, ob mit hoher Wahrscheinlichkeit bereits alle Knoten infiziert sind und Ausbreitung der Information gestoppt werden kann
- Robustheit:
 - Pro fehlerbehafteter Runde erhöht sich Gesamtzahl benötigter Runden um eins
 - Analyse kann auf Modell mit Infektionswahrscheinlichkeit erweitert werden

Frage: Wie lange es dauert bis alle Knoten infiziert sind, wenn anfangs ein Knoten infiziert ist?

Theorem ([Frieze/Grimmett '85])

Im Push-Modell sind nach $t = O(\log n)$ Runden mit hoher Wahrscheinlichkeit alle Knoten infiziert.

Anmerkungen:

- Mit zusätzlichem Zeitstempel kann überprüft werden, ob mit hoher Wahrscheinlichkeit bereits alle Knoten infiziert sind und Ausbreitung der Information gestoppt werden kann
- Robustheit:
 - Pro fehlerbehafteter Runde erhöht sich Gesamtzahl benötigter Runden um eins
 - Analyse kann auf Modell mit Infektionswahrscheinlichkeit erweitert werden
- Analyse des Zufallsprozesses auch für andere Graphstrukturen möglich

Notation für Analyse

- n: Anzahl der Knoten
- \bullet I(t): Anzahl der infizierten Knoten am Beginn von Runde t
- G(t): Anzahl der gesunden Knoten
- $i(t) = \frac{I(t)}{n}$: relativer Anteil der infizierten Knoten
- $g(t) = \frac{G(t)}{n}$: relativer Anteil der gesunden Knoten

Achtung: Zufallsvariablen

Notation für Analyse

- n: Anzahl der Knoten
- \bullet I(t): Anzahl der infizierten Knoten am Beginn von Runde t
- G(t): Anzahl der gesunden Knoten
- $i(t) = \frac{I(t)}{n}$: relativer Anteil der infizierten Knoten
- $g(t) = \frac{G(t)}{n}$: relativer Anteil der gesunden Knoten

Achtung: Zufallsvariablen

Für jede Runde t gilt: i(t) + g(t) = 1

Notation für Analyse

- n: Anzahl der Knoten
- \bullet I(t): Anzahl der infizierten Knoten am Beginn von Runde t
- G(t): Anzahl der gesunden Knoten
- $i(t) = \frac{I(t)}{n}$: relativer Anteil der infizierten Knoten
- $g(t) = \frac{G(t)}{n}$: relativer Anteil der gesunden Knoten

Achtung: Zufallsvariablen

Für jede Runde t gilt: i(t) + g(t) = 1

Ordnung der Knoten im Beweis: Bei der Analyse von Runde t nehmen wir eine beliebige Ordnung der infizierten Knoten an und bezeichen die Knoten mit $1,\ldots,I(t)$

Allgemeine Analyse

Frage

Wie hoch ist I(t + 1) in Abhängigkeit von I(t)?

Allgemeine Analyse

Frage

Wie hoch ist I(t + 1) in Abhängigkeit von I(t)?

Analysetrick:

ullet Anzahl der in Runde t infizierten Knoten ist schwer zu analysieren

Allgemeine Analyse

Frage

Wie hoch ist I(t + 1) in Abhängigkeit von I(t)?

Analysetrick:

- Anzahl der in Runde t infizierten Knoten ist schwer zu analysieren
- Stattdessen: Systematische Unterschätzung der Anzahl infizierter Knoten, die für unsere Zwecke gut genug ist

Frage

Wie hoch ist I(t + 1) in Abhängigkeit von I(t)?

Analysetrick:

- Anzahl der in Runde t infizierten Knoten ist schwer zu analysieren
- Stattdessen: Systematische Unterschätzung der Anzahl infizierter Knoten, die für unsere Zwecke gut genug ist
- Betrachte nur kollisionsfreie Infektionen

Frage

Wie hoch ist I(t + 1) in Abhängigkeit von I(t)?

Analysetrick:

- Anzahl der in Runde t infizierten Knoten ist schwer zu analysieren
- Stattdessen: Systematische Unterschätzung der Anzahl infizierter Knoten, die für unsere Zwecke gut genug ist
- Betrachte nur kollisionsfreie Infektionen

Definition

Ein Knoten j führt in Runde t eine kollisionsfreie Infektion durch, wenn

- j am Beginn von Runde t infiziert ist,
- der von j in Runde t angerufene Knoten am Beginn von Runde t gesund ist und
- der von j in Runde t angerufene Knoten in Runde t von keinem anderen infizierten Knoten als j angerufen wird

- **1** A_j : j ruft bereits infizierten Knoten an
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten

- A_j : j ruft bereits infizierten Knoten an $Pr[A_j] = \frac{I(t)}{n} = i(t)$
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten

- A_j : j ruft bereits infizierten Knoten an $\Pr[A_j] = \frac{I(t)}{n} = i(t)$
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten $\Pr[B_j] \leq \frac{I(t)-1}{n} \leq i(t)$

- A_j : j ruft bereits infizierten Knoten an $\Pr[A_j] = \frac{I(t)}{n} = i(t)$
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten $\Pr[B_j] \leq \frac{I(t)-1}{n} \leq i(t)$
- **②** $C_j : j$ führt kollisionsfreie Infektion durch $\Pr[C_j] \ge 1 \Pr[A_j \cup B_j] \ge 1 (\Pr[A_j] + \Pr[B_j]) \ge 1 2i(t)$

Drei Ereignisse für infizierten Knoten j in Runde t

- A_j : j ruft bereits infizierten Knoten an $\Pr[A_j] = \frac{I(t)}{n} = i(t)$
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten $\Pr[B_j] \leq \frac{I(t)-1}{n} \leq i(t)$
- **③** $C_j : j$ führt kollisionsfreie Infektion durch $\Pr[C_j] \ge 1 \Pr[A_j \cup B_j] \ge 1 (\Pr[A_j] + \Pr[B_j]) \ge 1 2i(t)$

Definiere Zufallsvariable

$$X_j(t) := \begin{cases} 1 & \text{falls } j \text{ eine kollisionsfreie Infektion durchführt} \\ 0 & \text{andernfalls} \end{cases}$$

Drei Ereignisse für infizierten Knoten j in Runde t

- A_j : j ruft bereits infizierten Knoten an $\Pr[A_j] = \frac{I(t)}{n} = i(t)$
- ② B_j : j ruft denselben Knoten an wie ein anderer infizierter Knoten $\Pr[B_j] \leq \frac{I(t)-1}{n} \leq i(t)$
- **③** $C_j : j$ führt kollisionsfreie Infektion durch $\Pr[C_j] \ge 1 \Pr[A_j \cup B_j] \ge 1 (\Pr[A_j] + \Pr[B_j]) \ge 1 2i(t)$

Definiere Zufallsvariable

$$X_j(t) := \begin{cases} 1 & \text{falls } j \text{ eine kollisionsfreie Infektion durchführt} \\ 0 & \text{andernfalls} \end{cases}$$

$$\Rightarrow \Pr[X_j(t) = 1] \ge 1 - 2i(t)$$

Analysiere erwarteten Anstieg für fixes i(t)

Analysiere erwarteten Anstieg für fixes i(t)

K(t): Anzahl der in Runde t kollisionsfrei infizierten Knoten

$$E[K(t)] = E\left[\sum_{j=1}^{I(t)} X_j(t)\right] = \sum_{j=1}^{I(t)} E[X_j(t)] \quad \text{(Linearität des Erwartungswerts)}$$

$$= \sum_{j=1}^{I(t)} \Pr[X_j(t) = 1] \ge \sum_{j=1}^{I(t)} (1 - 2i(t)) = I(t) - 2i(t)I(t)$$

Analysiere erwarteten Anstieg für fixes i(t)

K(t): Anzahl der in Runde t kollisionsfrei infizierten Knoten

$$E[K(t)] = E\left[\sum_{j=1}^{I(t)} X_j(t)\right] = \sum_{j=1}^{I(t)} E[X_j(t)] \quad \text{(Linearität des Erwartungswerts)}$$

$$= \sum_{j=1}^{I(t)} \Pr[X_j(t) = 1] \ge \sum_{j=1}^{I(t)} (1 - 2i(t)) = I(t) - 2i(t)I(t)$$

Erwartungswert des relativen Anteils infizierter Knoten nach Runde t:

$$E[i(t+1)] \ge E\left[i(t) + \frac{K(t)}{n}\right] = i(t) + \frac{E[K(t)]}{n} \ge i(t) + \frac{I(t) - 2i(t)I(t)}{n}$$
$$= i(t) + i(t) - 2i(t)^2 = 2i(t) - 2i(t)^2$$

Analysiere erwarteten Anstieg für fixes i(t)

K(t): Anzahl der in Runde t kollisionsfrei infizierten Knoten

$$E[K(t)] = E\left[\sum_{j=1}^{I(t)} X_j(t)\right] = \sum_{j=1}^{I(t)} E[X_j(t)] \quad \text{(Linearität des Erwartungswerts)}$$

$$= \sum_{j=1}^{I(t)} \Pr[X_j(t) = 1] \ge \sum_{j=1}^{I(t)} (1 - 2i(t)) = I(t) - 2i(t)I(t)$$

Erwartungswert des relativen Anteils infizierter Knoten nach Runde t:

$$\begin{split} E[i(t+1)] \geq E\left[i(t) + \frac{K(t)}{n}\right] &= i(t) + \frac{E[K(t)]}{n} \geq i(t) + \frac{I(t) - 2i(t)I(t)}{n} \\ &= i(t) + i(t) - 2i(t)^2 = 2i(t) - 2i(t)^2 \end{split}$$

Intuition für Analyse:

- $2i(t)^2$ anfangs vernachlässigbar
- Annähernd Verdopplung in jeder Runde

Beweisstrategie

Einteilung in zwei Phasen:

- Wachstum: $I(t) \le \frac{1}{3}n$ Dauer: $O(\log n)$ Runden
- **Schrumpfung:** $I(t) > \frac{1}{3}n$ Dauer: $O(\log n)$ Runden

Gesamtzahl an Runden: $O(\log n)$

In jeder Phase: Garantie mit hoher Wahrscheinlichkeit

I(t) wächst um Faktor $> \frac{7}{6}$ in jeder Runde mit konstanter Wahrscheinlichkeit

I(t) wächst um Faktor $> \frac{7}{6}$ in jeder Runde mit konstanter Wahrscheinlichkeit

Chernoff Bound

Seien X_1, \ldots, X_k unabhängige binäre Zufallsvariablen mit $\Pr[X_j = 1] = p$ und $\Pr[X_j = 0] = 1 - p$ und $\mu \ge E[\sum_{j=1}^k X_j] = pk$. Dann gilt für jedes $\delta \in [0, 1]$:

$$\Pr\left[\sum_{j=1}^{k} X_j \le (1-\delta) \cdot \mu\right] \le \frac{1}{e^{\frac{\delta^2}{2}\mu}}$$

I(t) wächst um Faktor $> \frac{7}{6}$ in jeder Runde mit konstanter Wahrscheinlichkeit

Chernoff Bound

Seien X_1, \ldots, X_k unabhängige binäre Zufallsvariablen mit $\Pr[X_j = 1] = p$ und $\Pr[X_j = 0] = 1 - p$ und $\mu \ge E[\sum_{j=1}^k X_j] = pk$. Dann gilt für jedes $\delta \in [0, 1]$:

$$\Pr\left[\sum_{j=1}^{k} X_j \le (1-\delta) \cdot \mu\right] \le \frac{1}{e^{\frac{\delta^2}{2}\mu}}$$

$$E[K(t)] = E\left[\sum_{j=1}^{I(t)} X_j(t)\right] \ge I(t) - 2i(t)I(t) \ge I(t) - 2 \cdot \frac{I(t)}{n} \frac{n}{3} = \frac{1}{3}I(t)$$

I(t) wächst um Faktor $> \frac{7}{6}$ in jeder Runde mit konstanter Wahrscheinlichkeit

Chernoff Bound

Seien X_1, \ldots, X_k unabhängige binäre Zufallsvariablen mit $\Pr[X_j = 1] = p$ und $\Pr[X_j = 0] = 1 - p$ und $\mu \ge E[\sum_{j=1}^k X_j] = pk$. Dann gilt für jedes $\delta \in [0, 1]$:

$$\Pr\left[\sum_{j=1}^{k} X_j \le (1-\delta) \cdot \mu\right] \le \frac{1}{e^{\frac{\delta^2}{2}\mu}}$$

$$E[K(t)] = E\left[\sum_{j=1}^{I(t)} X_j(t)\right] \ge I(t) - 2i(t)I(t) \ge I(t) - 2 \cdot \frac{I(t)}{n} \frac{n}{3} = \frac{1}{3}I(t)$$

Wahrscheinlichkeit, dass $K(t) \leq \frac{1}{6}I(t)$ (Wachstum nicht stark genug):

$$\Pr\left[\sum_{j=1}^{I(t)} X_j(t) \le \frac{1}{6} \cdot I(t)\right] = \Pr\left[\sum_{j=1}^{I(t)} X_j(t) \le (1 - \frac{1}{2}) \cdot \frac{1}{3}I(t)\right]$$

$$\le \frac{1}{e^{\frac{(\frac{1}{2})^2}{2} \cdot \frac{1}{3}I(t)}} = \frac{1}{e^{\frac{1}{24}I(t)}} \le \frac{1}{e^{\frac{1}{24}}}$$

- Runde t ist **schlecht** falls $I(t+1) \le \frac{7}{6}I(t)$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$

- Runde t ist **schlecht** falls $I(t+1) \le \frac{7}{6}I(t)$ $\Pr[I(t+1) \le \frac{7}{6}I(t)] \le \Pr[K(t) \le \frac{1}{6}I(t)] \le \frac{1}{e^{\frac{1}{24}}}$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$

- Runde *t* ist **schlecht** falls $I(t+1) \le \frac{7}{6}I(t)$ $\Pr[I(t+1) \le \frac{7}{6}I(t)] \le \Pr[K(t) \le \frac{1}{6}I(t)] \le \frac{1}{e^{\frac{1}{24}}}$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$ $\Pr[I(t+1) > \frac{7}{6}I(t)] = 1 - \Pr[I(t+1) \le \frac{7}{6}I(t)] \ge 1 - \frac{1}{e^{\frac{1}{24}}} \ge \frac{4}{100}$

Einteilung in **gute** und **schlechte** Runden:

- Runde t ist **schlecht** falls $I(t+1) \le \frac{7}{6}I(t)$ $\Pr[I(t+1) \le \frac{7}{6}I(t)] \le \Pr[K(t) \le \frac{1}{6}I(t)] \le \frac{1}{e^{\frac{1}{24}}}$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$ $\Pr[I(t+1) > \frac{7}{6}I(t)] = 1 - \Pr[I(t+1) \le \frac{7}{6}I(t)] \ge 1 - \frac{1}{e^{\frac{1}{24}}} \ge \frac{4}{100}$

Analyse:

• Nach höchstens $\log_{7/6} \frac{n}{3}$ guten Runden gilt $I(t) > \frac{1}{3}n$

Einteilung in **gute** und **schlechte** Runden:

- Runde *t* ist **schlecht** falls $I(t + 1) \le \frac{7}{6}I(t)$ $\Pr[I(t + 1) \le \frac{7}{6}I(t)] \le \Pr[K(t) \le \frac{1}{6}I(t)] \le \frac{1}{e^{\frac{1}{24}}}$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$ $\Pr[I(t+1) > \frac{7}{6}I(t)] = 1 - \Pr[I(t+1) \le \frac{7}{6}I(t)] \ge 1 - \frac{1}{e^{\frac{1}{24}}} \ge \frac{4}{100}$

Analyse:

- Nach höchstens $\log_{7/6} \frac{n}{3}$ guten Runden gilt $I(t) > \frac{1}{3}n$
- Erneute Anwendung der Chernoff-Bound: Bei $O(\log n)$ Runden mit hoher Wahrscheinlichkeit $\log_{7/6} \frac{n}{3}$ gute Runden

Einteilung in **gute** und **schlechte** Runden:

- Runde *t* ist **schlecht** falls $I(t+1) \le \frac{7}{6}I(t)$ $\Pr[I(t+1) \le \frac{7}{6}I(t)] \le \Pr[K(t) \le \frac{1}{6}I(t)] \le \frac{1}{e^{\frac{1}{24}}}$
- Runde t ist **gut** falls $I(t+1) > \frac{7}{6}I(t)$ $\Pr[I(t+1) > \frac{7}{6}I(t)] = 1 - \Pr[I(t+1) \le \frac{7}{6}I(t)] \ge 1 - \frac{1}{e^{\frac{1}{24}}} \ge \frac{4}{100}$

Analyse:

- Nach höchstens $\log_{7/6} \frac{n}{3}$ guten Runden gilt $I(t) > \frac{1}{3}n$
- Erneute Anwendung der Chernoff-Bound: Bei $O(\log n)$ Runden mit hoher Wahrscheinlichkeit $\log_{7/6} \frac{n}{3}$ gute Runden

Somit:

Phase 1 (Wachstum) benötigt mit hoher Wahrscheinlichkeit $O(\log n)$ Runden.

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Beispiel:

• $X_j(t) = 1$ impliziert, dass infizierter Knoten j keine Kollision mit anderem infizierten Knoten j' hat

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Beispiel:

- $X_j(t) = 1$ impliziert, dass infizierter Knoten j keine Kollision mit anderem infizierten Knoten j' hat
- Daher ist für j' die Möglichkeit der Kollision mit Knoten j bereits ausgeschlossen

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Beispiel:

- $X_j(t) = 1$ impliziert, dass infizierter Knoten j keine Kollision mit anderem infizierten Knoten j' hat
- Daher ist für j' die Möglichkeit der Kollision mit Knoten j bereits ausgeschlossen
- Dies "begünstigt", dass $X_{i'}(t) = 1$

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Beispiel:

- $X_j(t) = 1$ impliziert, dass infizierter Knoten j keine Kollision mit anderem infizierten Knoten j' hat
- Daher ist für j' die Möglichkeit der Kollision mit Knoten j bereits ausgeschlossen
- Dies "begünstigt", dass $X_{j'}(t) = 1$
- Somit: Keine unabhängigen Ereignisse

Achtung: Chernoff Bound gilt nur für unabhängige Variablen!

Aber: $X_j(t)$'s sind nicht unabhängig!

Beispiel:

- $X_j(t) = 1$ impliziert, dass infizierter Knoten j keine Kollision mit anderem infizierten Knoten j' hat
- Daher ist für j' die Möglichkeit der Kollision mit Knoten j bereits ausgeschlossen
- Dies "begünstigt", dass $X_{j'}(t) = 1$
- Somit: Keine unabhängigen Ereignisse

Dennoch gilt: Untere Schranke an die Wahrscheinlichkeit von $X_j(t) = 1$ unabhängig vom Ergebnis der anderen Zufallsvariablen

$$\Pr[X_j(t) = 1 \mid X_1(t) = x_1, \dots, X_{j-1}(t) = x_{j-1}] \ge 1 - 2i(t)$$

Stochastische Dominanz

Lemma (Doerr 2011)

Seien $X_1, ..., X_k$ beliebige binäre Zufallsvariablen und seien $Y_1, ..., Y_k$ unabhängige binäre Zufallsvariablen. Wenn für alle j und alle $x_1, ..., x_{j-1} \in \{0, 1\}$ gilt, dass

$$\Pr[X_j = 1 \mid X_1 = x_1, \dots, X_{j-1} = x_{j-1}] \ge \Pr[Y_j = 1]$$

 $dann\ gilt\ für\ alle\ T \ge 0$

$$\Pr\left[\sum_{j=1}^{k} X_j \le T\right] \le \Pr\left[\sum_{j=1}^{k} Y_j \le T\right]$$

Stochastische Dominanz

Lemma (Doerr 2011)

Seien $X_1, ..., X_k$ beliebige binäre Zufallsvariablen und seien $Y_1, ..., Y_k$ unabhängige binäre Zufallsvariablen. Wenn für alle j und alle $x_1, ..., x_{j-1} \in \{0, 1\}$ gilt, dass

$$\Pr[X_j = 1 \mid X_1 = x_1, \dots, X_{j-1} = x_{j-1}] \ge \Pr[Y_j = 1]$$

 $dann\ gilt\ für\ alle\ T \ge 0$

$$\Pr\left[\sum_{j=1}^{k} X_j \le T\right] \le \Pr\left[\sum_{j=1}^{k} Y_j \le T\right]$$

Abschätzung von $\Pr\left[\sum_{j=1}^{k} Y_j \leq T\right]$ durch Chernoff Bound

Stochastische Dominanz

Lemma (Doerr 2011)

Seien $X_1, ..., X_k$ beliebige binäre Zufallsvariablen und seien $Y_1, ..., Y_k$ unabhängige binäre Zufallsvariablen. Wenn für alle j und alle $x_1, ..., x_{j-1} \in \{0, 1\}$ gilt, dass

$$\Pr[X_j = 1 \mid X_1 = x_1, \dots, X_{j-1} = x_{j-1}] \ge \Pr[Y_j = 1]$$

 $dann\ gilt\ für\ alle\ T \ge 0$

$$\Pr\left[\sum_{j=1}^{k} X_j \le T\right] \le \Pr\left[\sum_{j=1}^{k} Y_j \le T\right]$$

Abschätzung von $\Pr\left[\sum_{j=1}^{k} Y_j \leq T\right]$ durch Chernoff Bound

Setze $Y_j = 1$ mit Wahrscheinlichkeit 1 - 2i(t) und 0 andernfalls

$$\Pr[X_j = 1 \mid X_1 = x_1, \dots, X_{j-1} = x_{j-1}] \ge 1 - 2i(t) = \Pr[Y_j = 1]$$

Schrumpfung: $I(t) > \frac{1}{3}n$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Schrumpfung: $I(t) > \frac{1}{3}n$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n}$$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1 - \frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}}$$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1 - \frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Ungleichung: $(1 - \frac{1}{x})^x \le \frac{1}{e}$ für $x \ge 1$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Ungleichung:
$$(1 - \frac{1}{x})^x \le \frac{1}{e}$$
 für $x \ge 1$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Ungleichung:
$$(1 - \frac{1}{x})^x \le \frac{1}{e}$$
 für $x \ge 1$

$$= \left(\left(1 - \frac{1}{n}\right)^{I(t)} \right)^{3(c+1)\ln n}$$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1-\frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Ungleichung:
$$(1 - \frac{1}{x})^x \le \frac{1}{e}$$
 für $x \ge 1$

$$= \left(\left(1 - \frac{1}{n} \right)^{I(t)} \right)^{3(c+1)\ln n} \le \left(\frac{1}{e^{1/3}} \right)^{3(c+1)\ln n}$$

Wechsel der Analyse: **Schrumpfung** gesunder Knoten statt Wachstum infizierter Knoten

Wahrscheinlichkeit, dass gesunder Knoten nicht infiziert wird: $\left(1 - \frac{1}{n}\right)^{I(t)}$

Obere Schranke:

$$\left(1 - \frac{1}{n}\right)^{I(t)} \le \left(1 - \frac{1}{n}\right)^{\frac{1}{3}n} = \left(\left(1 - \frac{1}{n}\right)^n\right)^{\frac{1}{3}} \le \left(\frac{1}{e}\right)^{\frac{1}{3}} = \frac{1}{e^{1/3}}$$

Ungleichung:
$$(1 - \frac{1}{x})^x \le \frac{1}{e}$$
 für $x \ge 1$

$$= \left(\left(1 - \frac{1}{n}\right)^{I(t)} \right)^{3(c+1)\ln n} \le \left(\frac{1}{e^{1/3}}\right)^{3(c+1)\ln n} = \frac{1}{e^{(c+1)\ln n}} = \frac{1}{n^{c+1}}$$

Schrumpfung: $I(t) \ge \frac{1}{3}n$ (Fortsetzung)

Mit **Union Bound**: Wahrscheinlichkeit, dass mindestens einer der gesunden Knoten in $3(c+1) \ln n$ aufeinanderfolgenden Runden nicht infiziert wird:

$$\leq n \cdot \frac{1}{n^{c+1}} = \frac{1}{n^c}$$

Schrumpfung: $I(t) \ge \frac{1}{3}n$ (Fortsetzung)

Mit **Union Bound**: Wahrscheinlichkeit, dass mindestens einer der gesunden Knoten in $3(c+1) \ln n$ aufeinanderfolgenden Runden nicht infiziert wird:

$$\leq n \cdot \frac{1}{n^{c+1}} = \frac{1}{n^c}$$

Gegenereignis: Jeder gesunde Knoten wird in $3(c+1) \ln n$ aufeinanderfolgenden Runden infiziert

Wahrscheinlichkeit $\geq 1 - \frac{1}{n^c}$

Schrumpfung: $I(t) \ge \frac{1}{3}n$ (Fortsetzung)

Mit **Union Bound**: Wahrscheinlichkeit, dass mindestens einer der gesunden Knoten in $3(c+1) \ln n$ aufeinanderfolgenden Runden nicht infiziert wird:

$$\leq n \cdot \frac{1}{n^{c+1}} = \frac{1}{n^c}$$

Gegenereignis: Jeder gesunde Knoten wird in $3(c+1) \ln n$ aufeinanderfolgenden Runden infiziert

Wahrscheinlichkeit $\geq 1 - \frac{1}{n^c}$

Somit:

Phase 2 (Schrumpfung) benötigt mit hoher Wahrscheinlichkeit $O(\log n)$ Runden.

Zusammenfassung

Informationsausbreitung im Push-Modell:

- Wachstum: $I(t) \le \frac{1}{3}n$ Dauer: $O(\log n)$ Runden mit hoher Wahrscheinlichkeit
- **Schrumpfung:** $I(t) > \frac{1}{3}n$ Dauer: $O(\log n)$ Runden mit hoher Wahrscheinlichkeit

Informationsausbreitung im Pull-Modell:

- $O(\log n)$ Runden mit hoher Wahrscheinlichkeit
- Analyse benötigt ähnliche Beweistechniken wie im Push-Modell

Quellen

Der Inhalt dieser Vorlesungseinheit basiert zum Teil auf Vorlesungseinheiten von Robert Elsässer und Christian Schindelhauer.

Literatur:

- Alan J. Demers et al. "Epidemic Algorithms for Replicated Database Maintenance". Operating Systems Review 22(1): 8–32 (1988)
- Benjamin Doerr, Marvin Künnemann. "Tight Analysis of Randomized Rumor Spreading in Complete Graphs". In: Proc. of the Workshop on Analytic Algorithmics and Combinatorics (ANALCO). 2014, S. 82–91
- Alan M. Frieze, Geoffrey R. Grimmett. "The shortest-path problem for graphs with random arc-lengths". *Discrete Applied Mathematics* 10(1): 57–77 (1985)